

# 说话人识别中的 PLDA 自适应

作者|周健峰

单位|厦门大学智能语音实验室

联系方式|jifchou@stu.xmu.edu.cn

## 本文纲要：

- 一、数据域差衡量
- 二、CORAL
  - 2.1 feature-based domain adaptation
  - 2.2 model-based domain adaptation
  - 2.3 CORAL 方法的理论推导
- 三、CORAL+
  - 3.1 参数插值
  - 3.2 参数规整
- 四、Kaldi APLDA
- 五、监督线性差值法(LIP)
- 六、相关对齐差值法(CIP)
  - 6.1 基于 CORAL 的监督参数调整法
  - 6.2 基于 CORAL+的监督参数调整法
- 七、PLDA 自适应方式实验验证
  - 7.1 NEC 验证实验
  - 7.2 XMU 验证实验
- 八、工程简介

## 本文说明：

- 1.本文中使用的说话人表征均使用 i-vectors 进行表示。
- 2.本文中的实验均基于 NIST SRE 数据集

在 PLDA 模型的训练当中，我们通过最大似然的估计方法获取得到了模型的假设分布参数(一般假设为高斯分布)。并且通过已有数据获取得到的参数估计进行预测估计。由于参数的获取来自于训练数据，因此当测试数据与训练数据存在域差时，通过训练数据估计得到的参数无法准确的衡量测试数据的分布。为了能够使得学习到的参数对域外数据能够正确建模，需要通过一定的手段调整学习到的 PLDA 参数(全局均值，类间协方差，类内协方差)，进而提升域外测试集的性能。在说话人识别当中，常用的参数调整方式包括 Kaldi

中的自适应(Kaldi-APLDA)、CORAL、CORAL+、FDA 以及 CIP。本文中我们将分别介绍各种领域自适应方法的参数调整方式。

## 一、数据域差衡量

在说话人识别任务当中，除了直观的理解上对域差的判断，常常使用说话人表征的 TSNE 分布图进行域差衡量。如图 1.1 中所示分布即表明两份数据之间在不同域空间，存在域差。

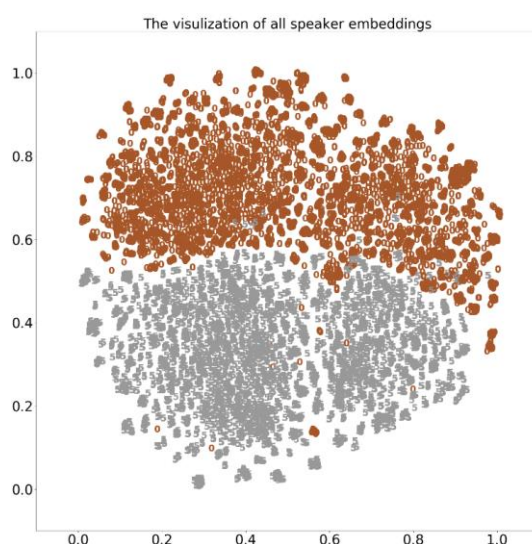


图 1.1 SRE04-08 数据说话人表征与 SRE18-eval 数据说话人表征 TSNE 分布图。

由图 1.1 中的分布可知，SRE04-08 数据与 SRE18-eval 数据为不同域数据。

## 二、CORAL

### 2.1 feature-based domain adaptation

Correlation alignment (CORAL)是一种无监督的领域自适应方法。CORAL 通过域外数据学习得到的参数(类间协方差和类内协方差)进行调整，使得参数能够与域内数据分布匹配从而能够准确的估计域内数据之间的相关关系。具体来说，CORAL 自适应方法包含两个步骤：Whitening 和 Re-coloring。CORAL 首先通过 Whitening 操作去除原始数据维度之间

的相关性，进而通过 Re-coloring 操作将域内数据的维度相关性赋予参数。相关操作对于分布的影响如图 2.1 所示。




图 2.1 Whitening 操作以及 Re-coloring 操作对于数据分布的影响。其中红色表示 Target Domain，蓝色表示 Source Domain。左图至中图的变化为 Source 的 Whitening 处理，中图至右图为 Re-coloring 处理。

由图 2.1 的可视化模拟可知，通过 CORAL 的处理，能够将 Source Domain 的数据转换至 Target Domain 当中。方差决定了数据传播的大小，而协方差决定了方向。因此白化和 Re-coloring 的操作就是去除原始分布的方向，将其映射到新的数据的方向上。其处理过程的数学表示如表 2.1 所示。

表 2.1 CORAL 数据处理流程

符号说明： $\Phi_W$ 表示类内协方差矩阵， $\Phi_B$ 表示类间协方差矩阵， $Q$ 表示矩阵特征向量， $\Lambda$ 表示矩阵特征值。		
步骤	处理方式	数学表达
1	求取总协方差矩阵	$C_O = \Phi_{W,O} + \Phi_{B,O}, C_I = \Phi_{W,I} + \Phi_{B,I}$
2	求取 Whiten 与 Re-coloring 矩阵	$C_O^{-\frac{1}{2}} = Q_O \Lambda_O^{-\frac{1}{2}} Q_O^t, C_I^{-\frac{1}{2}} = Q_I \Lambda_I^{-\frac{1}{2}} Q_I^t$
2	Whitening	$\phi_w = C_O^{-\frac{1}{2}} \phi$
3	Re-coloring	$\phi_r = C_I^{-\frac{1}{2}} C_O^{-\frac{1}{2}} \phi_w$

通过表 2.1 的转换方式，便可将 Source Domain 的数据分布转换到 Target Domain 的数据空间当中。得到转换后的新的向量 $\phi_r$ 后，便可使用 $\phi_r$ 训练 PLDA 模型，进而进行打分操作。

## 2.2 Model-based domain adaptation

在 2.1 小节中我们已经介绍 CORAL 的 feature-based 域自适应方法，该方法直接对向量进行转换，得到新的向量用于训练 PLDA 模型。实际由高斯分布的变换可知，对于服从高斯分布 $x \sim N(\mu, \Sigma)$ 的数据统一乘上某个矩阵 $T$ ，则新的数据的方差矩阵为 $T^T \Sigma T$ 。由以上性质可知，对于 feature-based 的 CORAL 方法，可直接对模型的参数进行调整而不必进行数据的转换。Model-based 的 CORAL 转换如式 2.1 以及式 2.2 所示。

$$\Phi_{W,C} = A^T \Phi_{W,O} A \quad (2.1)$$

$$\Phi_{B,C} = A^T \Phi_{B,O} A \quad (2.2)$$

其中转换矩阵 $A = C_I^{\frac{1}{2}} C_O^{-\frac{1}{2}}$ 。

注：在本文实验中的 CORAL 为 Model-based。

## 2.3 CORAL 方法的理论推导

CORAL 全称为 Correlation Alignment，该方法通过对齐经过线性转换的 Source Domain 数据协方差和 Target Domain 数据的协方差实现 Domain Adaptation 的目的。假设我们有 Source Domain 的数据  $D_S = \vec{x}_i, \vec{x}_i \in \mathfrak{R}^D$ ，还有 Target Domain 的数据  $D_T = \vec{u}_i, \vec{u}_i \in \mathfrak{R}^D$ 。假设 $\mu_s$ ， $\mu_t$ 和 $C_S$ 和 $C_T$ 分别为源数据和目标数据的均值和协方差。为了最小化 Source Domain 和 Target Domain 之间的协方差距离，我们可以对 Source Domain 的协方差进行线性转换，然后使用 Frobenius norm 作为矩阵之间距离的衡量。则其最小化方式如式 2.3 所示。

$$\min_A \|C_S - C_T\|_F^2 = \min_A \|A^T C_S A - C_T\| \quad (2.3)$$

其中 $C_{\hat{S}}$ 为进行线性转换后的矩阵， $\|\cdot\|_F^2$ 表示矩阵的 Frobenius norm。如果 $\text{rank}(C_S) \geq \text{rank}(C_T)$ ，则我们可以选择一个线性转换 $A$ 使得 $C_{\hat{S}} = C_T$ 。然而在大多数情况下，数据都在低维空间中建模，因此协方差矩阵大概率为低秩矩阵。接下来我们就给出矩阵 $A$ 的最优解，以及相应的证明。

**引理 1：** 假设 $Y, X$ 是秩分别为 $r_Y, r$ 的矩阵，其中 $r \leq r_Y$ 。对矩阵 $Y$ 进行 SVD 分解得到， $Y = U_Y \Sigma_Y V_Y$ 并且 $U_{Y[1:r]} \Sigma_{Y[1:r]} V_{Y[1:r]}$ 为其最大 $r$ 个特征值所对应的矩阵的乘积。则对于问题 $\min_X \|X - Y\|_F^2$ ，其最优解为 $X \dots \dots = U_{Y[1:r]} \Sigma_{Y[1:r]} V_{Y[1:r]}$ 。

**定理 1：** 令 $\Sigma^+$ 为矩阵 $\Sigma$ 的广义逆矩阵， $r_{C_S}$ 和 $r_{C_T}$ 为矩阵 $C_S$ 和矩阵 $C_T$ 的秩。则 $A^* =$

$U_S \Sigma_S^{+\frac{1}{2}} U_S^T U_{T[1:r]} \Sigma_{T[1:r]}^{\frac{1}{2}} U_{T[1:r]}^T$ 是式(14)的最优解，其中 $r = \min(r_{C_S}, r_{C_T})$ 。

**定理 1 的证明：** 因为矩阵 $A$ 为线性变换，因此 $A^T C_S A$ 并不会使得矩阵得秩变大，因此 $r_{C_{\hat{S}}} \leq r_{C_S}$ 。又因为 $C_S$ 和矩阵 $C_T$ 为对称矩阵，因此可对其进行 SVD 分解得到 $C_S = U_S \Sigma_S U_S^T$ ， $C_T = U_T \Sigma_T U_T^T$ 。那么我们可以考虑一下两种情况：

**Case1：** 当 $r_{C_S} > r_{C_T}$ 时，此时最优解 $C_{\hat{S}} = C_T = U_T \Sigma_T U_T^T$ 。

**Case2：** 当 $r_{C_S} \leq r_{C_T}$ 时，那么根据引理 1 我们可得最优解 $C_{\hat{S}} = U_{T[1:r_{C_S}]} \Sigma_{T[1:r_{C_S}]} U_{T[1:r_{C_S}]}^T$ 。

根据以上两种情况，我们可知最优解为 $C_{\hat{S}} = U_{T[1:r]} \Sigma_{T[1:r]} U_{T[1:r]}^T$ 。其中 $r = \min(r_{C_S}, r_{C_T})$ 。又我们可知， $C_{\hat{S}} = A^T C_S A$ ，因此可得式 2.4。

$$A^T C_S A = U_{T[1:r_{C_S}]} \Sigma_{T[1:r_{C_S}]} U_{T[1:r_{C_S}]}^T \quad (2.4)$$

又 $C_S = U_S \Sigma_S U_S^T$ ，我们可得

$$A^T U_S \Sigma_S U_S^T A = (U_S^T A)^T \Sigma_S (U_S^T A) = U_{T[1:r_{C_S}]} \Sigma_{T[1:r_{C_S}]} U_{T[1:r_{C_S}]}^T \quad (2.5)$$

令 $E = \Sigma_S^{+\frac{1}{2}} U_S^T U_{T[1:r]} \Sigma_{T[1:r]}^{\frac{1}{2}} U_{T[1:r]}^T$ ，则

$$(U_S^T A)^T \Sigma_S (U_S^T A) = E^T \Sigma E \quad (2.6)$$

令  $U_S^T A = E$ ，我们可得  $A$  的解为

$$A^* = U_S E = (U_S \Sigma_S^{+\frac{1}{2}} U_S^T) (U_{T[1:r_{c_S}]} \Sigma_{T[1:r_{c_S}]} U_{T[1:r_{c_S}]}^T) \quad (2.7)$$

通过以上的公式推导，我们可得到最优的转换矩阵  $A^*$ 。进而我们可对式 2.7 的进行分解便可得到 2.1 节中的直观过程：白化  $(U_S \Sigma_S^{+\frac{1}{2}} U_S^T)$  以及 Re-coloring  $(U_{T[1:r_{c_S}]} \Sigma_{T[1:r_{c_S}]} U_{T[1:r_{c_S}]}^T)$ 。

**注：**由于协方差矩阵为半正定或者正定，为了编码半正定导致矩阵非满秩无法求逆的问题，在实际的处理中，我们常常给对角矩阵  $\Sigma$  加上一个规整项，使得矩阵满秩（方便求逆等计算）。

### 三、CORAL+

#### 3.1 参数插值

CORAL+是 CORAL 的改进版本，不同于 CORAL 中直接使用进行线性转换后的矩阵替代原始 Source Domain 计算得到的协方差，CORAL+中使用插值的方式计算新的协方差矩阵。其计算方式如式 3.1 以及 3.2 所示。

$$\Phi_b^+ = (1 - \beta) \Phi_{b,o} + \beta A^T \Phi_{b,o} A \quad (3.1)$$

$$\Phi_w^+ = (1 - \lambda) \Phi_{w,o} + \lambda A^T \Phi_{w,o} A \quad (3.2)$$

其中  $\{\beta, \lambda\} \in [0, 1]$  为自适应参数。将其简化为式 3.3 以及式 3.4。

$$\Phi_b^+ = \Phi_{b,o} + \beta (A^T \Phi_{b,o} A - \Phi_{b,o}) \quad (3.3)$$

$$\Phi_w^+ = \Phi_{w,o} + \lambda(A^T \Phi_{w,o} A - \Phi_{w,o}) \quad (3.4)$$

其中右边的第二项可以理解为 in-domain 数据所带来的新的信息。

### 3.2 参数规整

Domain Adaptation 是将 Out-of-Domain 数据中未涵盖到的空间囊括进分布空间中，但是 3.1 式中的插值方式，并不能保证分布空间的扩增(In-domain 数据方向上的方差值增大)。为了减少不确定性，涵盖更广范围内的空间，CORAL+中对插值处理进行选择性的插值。具体来说，CORAL+中通过合同对角化，将 Out-of-Domain 的数据和 In-Domain 的数据映射到同一个空间，在该空间中比较某个方向上的方差值大小，当 In-Domain 数据的方差值大于 Out-of-Domain 数据的方差值时，对该方向上的参数进行插值处理。其具体处理方式如表 3.1 所示。

表 3.1 CORAL+中的参数规整流程

符号说明： $E$ 为特征值对角矩阵。		
步骤	处理方式	数学表达
1	对转换后 Out-of-Domain 的数据参数 $A^T \Phi A$ 以及 Out-of-Domain 的参数 $\Phi$ 进行合同对角化	通过 Choskey 分解求得正交矩阵 $B$ 使得 $B^T \Phi_{b,o} B = I$ $B^T (A^T \Phi_{b,o} A) B = E_b$ $B^T \Phi_{w,o} B = I$ $B^T (A^T \Phi_{w,o} A) B = E_w$
2	选取新空间下 $A^T \Phi A$ 的方差与 $\Phi$ 方差大值	$\max(E_b, I), \max(E_w, I)$
3	将调整后的方差值还原回原始空间进行插值处理	$\Phi_b^+ = \Phi_{b,o} + \beta B_b^{-T} \max(E_b, I) B_b^{-1}$ $\Phi_w^+ = \Phi_{w,o} + \beta B_w^{-T} \max(E_w, I) B_w^{-1}$

通过表 3.2 所示的方式即可实现 In-Domain 数据的信息补充作用，使得新的参数囊括 In-Domain 数据空间。

#### 四、Kaldi-APLDA

Kaldi 中 APLDA 的处理方式与 CORAL 的处理方式类似。其参数方式见表 4.1。

<b>前言：</b> 由 PLDA 的计算，我们已经得到以下参数：转换矩阵 $A$ ，对角特征值矩阵 $\psi$ 。通过转换矩阵 $A$ 的处理，能够将数据映射到新的空间当中，在该空间下总协方差矩阵为 $(1+\psi) * I$ 。参数说明：其中 $B$ 为类间协方差矩阵； $W$ 为类内协方差矩阵；		
步骤	处理方式	数学表达
1	求取新的准换矩阵 $A'$ ，使得经过矩阵 $A^*$ 准换后，数据映射到一级空间 $Q_1$ ，在该映射空间中总的协方差矩阵为单位阵。	$A^* = A * (\frac{1}{1 + \psi})$
2	求解将域外总协方差矩阵 $C_I$ 映射到一级空间 $Q_1$ 中	$C_I^1 = A^* C_I A^{*T}$
3	求取 $C_I^1$ 的特征值和特征向量	$S, P = \text{Eig}(C_I^1)$
4	求解新空间下的类间协方差以及类内协方差	$W_O^1 = \frac{1}{1 + \psi}$ $B_O^1 = \frac{\psi}{1 + \psi}$
5	将类间协方差和类内协方差进一步映射到二级空间 $Q_2$ 中，在该空间中域内协方差参数为特征值对角阵。	$W_O^2 = P^T W_O^1 P$ $B_O^2 = P^T B_O^1 P$
6	在二级空间中比较域内参数与域外参数的特征值大小(此使域外参数的特征值为1)，倘若特征值大于1则，进行特征值的加权插值	If $S[i] > 1$ : $W_O^2[i][i] += w_{scale} * (S[i] - 1)$ $B_O^2[i][i] += b_{scale} * (S[i] - 1)$



7	将插值后的类内协方差矩阵于类间协方差矩阵还原至最原始的空间得到新的类间协方差矩阵于类内协方差矩阵	$W_{new} = (P^T A^*)^{-1} W_O^2 (P^T A^*)^{-T}$ $B_{new} = (P^T A^*)^{-1} B_O^2 (P^T A^*)^{-T}$
8	进行 Kaldi-PLDA 打分	-

与 CORAL+相比，Kaldi APLDA 的插值方式为特征值插值，而 CORAL+在参数插值。

## 五、监督线性差值法(LIP)

在以上所提到的参数调整方法均为无监督的参数调整方式，对于部分能够获取得到一定量的域内带标签数据的场景，可以使用监督插值方法进行参数调整。具体来说，可同时利用大量的域外数据求解得到域外 PLDA 参数以及使用域内数据训练得到域内 PLDA 参数。在求解得到以上两组参数后，便可通过差值法进行参数调整，其调整方式如式 5.1 以及 5.2 所示。

$$\Phi_b^+ = \alpha \Phi_{b,I} + (1 - \alpha) \Phi_{b,O} \quad (5.1)$$

$$\Phi_w^+ = \beta \Phi_{w,I} + (1 - \beta) \Phi_{w,O} \quad (5.2)$$

其中 $\alpha$ ， $\beta$ 为插值比例。

## 六，相关对齐插值法

### 6.1 基于 CORAL 的监督参数调整法

虽然监督差值法简单且能够取得较大的性能增益，但是当域内与域外的属于差异过大时，简单的插值法所能带来的性能增益将受到域外数据的影响，且性能较依赖于插值比例的选择。基于以上的考虑，论文[3]提出了相关对齐差值法。简单来说，不再直接使用域外参数和域内参数直接进行插值，而是使用 CORAL 转换后的矩阵进行插值处理。

$$\Phi_b^+ = \alpha \Phi_{b,I} + (1 - \alpha) A^T \Phi_{b,o} A \quad (6.1)$$

$$\Phi_w^+ = \beta \Phi_{w,I} + (1 - \beta) A^T \Phi_{w,o} A \quad (6.2)$$

通过以上参数调整方式即可一定程度避免域内域外数据偏差过大对实验性能的影响,进一步提升域不匹配场景下的性能。

## 6.2 基于 CORAL+ 的监督参数调整法

同样为了保证插值的准确性(通过插值处理后,参数对域内数据的描述更准确),相关对齐差值法中同样进行了 CORAL+ 中的参数规整方式。其参数调整方式见表 3.1,差别在于将其中的域外参数更换为了域内参数。

# 七, PLDA 自适应方式实验验证

## 7.1 NEC 验证实验

本小节中的实验结果选取自 ICASSP2020 论文<A Generalized Framework for Domain Adaptation of PLDA in Speaker Recognition>

表 7.1 NEC 实验部分配置信息

网络框架	The x-vector extractor is a 43-layers TDNN with residual connections and a 2-head attentive statistics pooling
网络训练数据	Switchboard, VoxCeleb 1 and 2, and SREs04–06,08,10,and12
Out-of-Domain PLDA 训练数据	SREs04–06,08,10,and12
In-Domain PLDA 训练数据	SRE18-Eval

测试数据	SRE18-Dev
后处理	取均值, LDA

注：Out-of-Domain PLDA 训练数据中包含来自 4,322 人的 262,427 条句子;In-Domain PLDA 训练数据中包含有来自 940 人的 13451 条语音。

表 7.2 NEC 实验验证结果

系统	EER(%)	minC_primary
PLDA	4.38	0.249
CORAL+	3.95	0.217
In-Domain PLDA	4.15	0.293
LIP	<b>3.58</b>	0.195
LIP-Reg	<b>3.58</b>	0.195
CIP	3.68	0.186
CIP-Reg	<b>3.58</b>	<b>0.173</b>

注：插值比例均为 0.5

#### 实验现象：

- 直接使用 In-Domain 数据训练的 PLDA 模型能够取得比 Out-of-Domain 训练 PLDA 更好的 EER 性能，但是 C\_primary 的性能较差
- CORAL+在跨域任务上能够取得较好的性能结果
- 监督插值的方法能够取得比无监督更好的性能
- 相关插值方法相比于简单插值方法能够取得**更好的 C\_Primary 性能**

注：NEC 实验中未和 Kaldi 中的 PLDA 自适应方法进行比较。

7.2 XMU 验证实验

本文中使用 XMU 训练的 x-vector 系统进行了 Domain Adaptation 方法的实验验证。实验相应配置以及实验结果见表 7.3 以及表 7.4。

表 7.3 NEC 实验部分配置信息

网络框架	x-vector
网络训练数据	Switchboard, and SREs04–06,08,10,and12
Out-of-Domain PLDA 训练数据	SREs04–06,08,10,and12
In-Domain PLDA 训练数据	SRE18-Eval
测试数据	SRE18-Dev
后处理	无

表 7.4 XMU PLDA 自适应方式实验验证结果

模型	自适应方法	EER(%)	minDCF08	minDCF10	C_primary
x-vector	PLDA	12.96	0.7018	0.8765	0.7280
	Kaldi-APLDA	9.565	0.6644	0.8443	0.6980
	CORAL	8.761	0.6169	0.7945	0.6423
	In-Domain	8.173	0.5384	0.7150	0.5686
	CORAL+	7.624	0.6039	0.8072	0.6365
	Lip	6.845	0.5216	0.7314	0.5548
	LIP-Reg	7.037	0.5177	0.7058	0.5459
	CIP	6.257	0.5150	0.7367	0.5481
	CIP-Reg-	6.347	0.5243	0.7356	0.5591

注：其中 LIP 的插值权重为 0.4；CIP 的插值权重为 0.5。

## 实验现象：

- CORAL 能够取得比 Kaldi PLDA 更好的实验效果
- In-Domain 数据训练的 PLDA，即使在训练数据量上与域外数据存在量差(句子数比为 19.5:1)，但是使用域内数据能够取得相比于 Kaldi APLDA 以及 CORAL 都更好的实验结果
- 在无监督 PLDA 自适应上 CORAL+能够取得最优异的性能效果
- 监督差值法(LIP)比无监督 PLDA 自适应的效果更好
- 相关差值法在有域内监督数据时能够取得最优异的性能

注：在线性插值法与相关差值法规整上本小节中的实验未取得与 NEC 一致的效果。因为当朝着域外方向增长方差时，域差过大的情况下，域外学习到的信息不足以弥补域差所带来的型嫩下降。

除了以上实验结果，本文中還选取了不同的插值参数进行实验效果验证。结果见图 7.1 所示。














图 7.1 不同插值权重下的实验结果对比图

PLDA 自适应对性能的影响：EER(12.96→**6.257**);C<sub>primary</sub>(0.7280→**0.5363**)，部分结果见附表 1.

## 八、Domain Adaptation 工程介绍

本工程均使用编程语言 Python 实现以上方法，且数据处理方式与 Kaldi 能够兼容，能够直接与 Kaldi 进行对接。且以上方法均为模型参数调整方法，多为矩阵运算，因此计算量不大，且更改后的参数能够直接使用 Kaldi 进行打分处理，效率较高。

本工程中包含代码如下图所示：

 DomainVisualization	2020/5/11 17:24	PY 文件	2 KB
 ivector-adapt-plda	2020/5/13 20:49	PY 文件	1 KB
 ivector-adapt-plda-cip	2020/5/14 11:35	PY 文件	6 KB
 ivector-adapt-plda-cip-reg	2020/5/14 11:53	PY 文件	7 KB
 ivector-adapt-plda-coral	2020/5/13 16:06	PY 文件	5 KB
 ivector-adapt-plda-coralplus	2020/5/13 13:12	PY 文件	6 KB
 ivector-adapt-plda-coral-trans	2020/5/13 16:11	PY 文件	5 KB
 ivector-adapt-plda-fda	2020/5/10 23:48	PY 文件	6 KB
 ivector-adapt-plda-lip	2020/5/13 23:37	PY 文件	2 KB
 ivector-adapt-plda-lip-reg	2020/5/14 0:14	PY 文件	4 KB

其中包含有域差可视化代码以及 Kaldi APLDA 的 Python 实现，CORAL、CORAL+、LIP、CIP 等 PLDA 自适应方法的 Python 实现。

参考文献：

[1] Sun B, Feng J, Saenko K. Return of frustratingly easy domain adaptation[C]//Thirtieth AAAI Conference on Artificial Intelligence. 2016.

[2] Lee K A, Wang Q, Koshinaka T. The CORAL+ algorithm for unsupervised domain adaptation of PLDA[C]//ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2019: 5821-5825.

[3] Wang, Qiongqiong & Okabe, Koji & Lee, Kong & Koshinaka, Takafumi. (2020). A Generalized Framework for Domain Adaptation of PLDA in Speaker Recognition. 6619-6623. 10.1109/ICASSP40776.2020.9054113.

[4] D.Garcia-Romero and A.McCree, "Supervised domain adaptation for i-vector based speaker recognition," in Proc. IEEE ICASSP, 2014.

附表 1：

附表 1. 不同插值权重下实验结果

模型	自适应方法	EER(%)	minDCF08	minDCF10	C_primary
----	-------	--------	----------	----------	-----------

x-vector	Lip-0.9	8.122	0.6119	0.8321	0.6508
	Lip-0.8	7.471	0.5736	0.7948	0.6144
	Lip-0.7	7.139	0.5516	0.7704	0.5899
	Lip-0.6	6.973	0.5377	0.7494	0.5743
	Lip-0.5	6.883	0.5263	0.7448	0.5621
	Lip-0.4	6.845	0.5216	0.7314	0.5548
	Lip-0.3	7.049	0.5133	0.7212	0.5449
	Lip-0.2	7.151	0.5135	0.7180	0.5437
	Lip-0.1	7.420	0.5191	0.6983	0.5473
	LIP-Reg-0.9	7.484	0.5181	0.6950	0.5454
	LIP-Reg-0.8	7.241	0.5139	0.7127	0.5435
	LIP-Reg-0.7	7.139	0.5142	0.7082	0.5424
	LIP-Reg-0.6	7.037	0.5177	0.7058	0.5459
	LIP-Reg-0.5	7.037	0.5206	0.7156	0.5493
	LIP-Reg-0.4	7.075	0.5248	0.7203	0.5525
	LIP-Reg-0.3	7.088	0.5291	0.7211	0.5580
	LIP-Reg-0.2	7.164	0.5336	0.7211	0.5627
	LIP-Reg-0.1	7.139	0.5364	0.7219	0.5661
	CIP-0.9	7.509	0.5798	0.7728	0.6065
	CIP-0.8	6.985	0.5565	0.7622	0.5877
	CIP-0.7	6.538	0.5403	0.7482	0.5696
	CIP-0.6	6.360	0.5241	0.7355	0.5566
	CIP-0.5	<b>6.257</b>	0.5150	0.7367	0.5481
	CIP-0.4	6.270	0.5068	0.7204	0.5407
	CIP-0.3	6.436	0.5010	0.7176	<b>0.5363</b>
	CIP-0.2	6.832	0.5072	0.6991	0.5432

	CIP-0.1	7.279	0.5166	0.6897	0.5496
	CIP-Reg-0.9	6.347	0.5275	0.7404	0.5633
	CIP-Reg-0.8	6.347	0.5243	0.7356	0.5591
	CIP-Reg-0.7	6.385	0.5196	0.7307	0.5553
	CIP-Reg-0.6	6.462	0.5171	0.7239	0.5525
	CIP-Reg-0.5	6.513	0.5129	0.7176	0.5491
	CIP-Reg-0.4	6.653	0.5142	0.7138	0.5497
	CIP-Reg-0.3	6.845	0.5155	0.7040	0.5489
	CIP-Reg-0.2	7.164	0.5166	0.6884	0.5502
	CIP-Reg-0.1	7.458	0.5231	0.6895	0.5548